LAPORAN TUGAS PRAKTIKUM 3: CLASSIFICATION DENGAN ENSEMBLE METHOD & CLASS IMBALANCE

Nama: Maulana Rhys Pradana

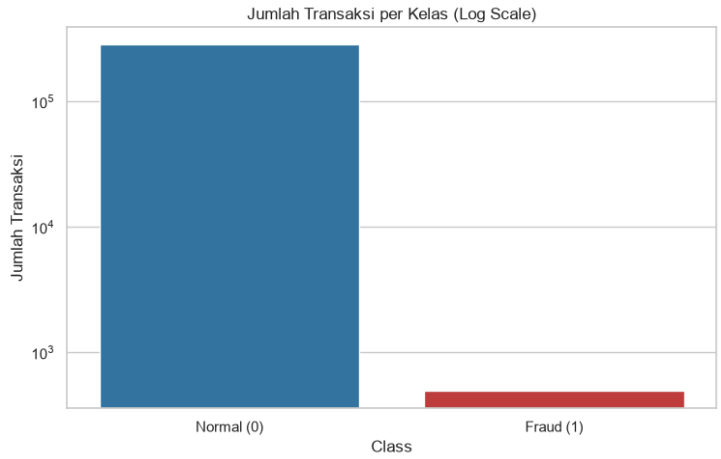
NRP: 5054251041

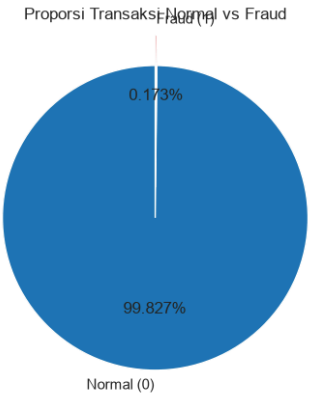
1. Pendahuluan dan Analisis Distribusi Kelas Awal
Praktikum ini menggunakan dataset Credit Card Fraud Detection yang memuat data histori transaksi kartu kredit di Eropa. Tujuan utama klasifikasi ini adalah membangun model yang mampu membedakan transaksi legal (Normal) dari tindak kejahatan finansial (Fraud).

Dari proses pemuatan data, diketahui bahwa dataset ini memiliki 284.807 baris. Namun, distribusi pada variabel target (Class) menunjukkan ketidakseimbangan kelas (class imbalance) yang sangat ekstrem:

- **Kelas 0 (Transaksi Normal):** 284.315 sampel, mendominasi **99,83%** dari keseluruhan data.
- **Kelas 1 (Transaksi Fraud):** 492 sampel, hanya mewakili **0,17%** dari keseluruhan data.

	Jumlah Sampel	Persentase (%)
Normal (0)	284315	99.827251
Fraud (1)	492	0.172749





Analisis Masalah Ketidakseimbangan Kelas: Visualisasi di atas dengan jelas memperlihatkan bahwa kelas minoritas (Fraud) sangat tertinggal dibandingkan kelas mayoritas. Dalam skenario *machine learning*, algoritma standar cenderung mengoptimalkan akurasi keseluruhan. Dengan distribusi 99,83% berbanding 0,17%, sebuah model dapat

dengan mudah memprediksi "Normal" untuk *setiap* transaksi dan mendapatkan akurasi sebesar 99,83%. Fenomena ini disebut sebagai *Accuracy Paradox*. Meskipun akurasinya nyaris sempurna, model tersebut sama sekali tidak berguna karena gagal mendeteksi satu pun transaksi penipuan. Oleh karena itu, diperlukan teknik khusus untuk menangani *class imbalance* ini agar model dapat mengenali pola transaksi Fraud dengan baik.

2. Pendekatan untuk Menangani Class Imbalance

Sebelum melakukan penanganan imbalance, data terlebih dahulu dipraproses. Atribut Time dan Amount diskalakan menggunakan StandardScaler agar rentang nilainya sepadan dengan fitur V1-V28 (yang merupakan hasil transformasi PCA). Selanjutnya, data dibagi menjadi data latih (training set) dan data uji (testing set) dengan rasio 80:20 menggunakan parameter stratify=y untuk menjaga proporsi awal kelas minoritas di kedua set pembagian.

Untuk mengatasi ketimpangan jumlah kelas pada data latih, pendekatan yang digunakan adalah metode oversampling, yaitu SMOTE (Synthetic Minority Over-sampling Technique).

Bagaimana SMOTE Bekerja:
Berbeda dengan Random Oversampling yang hanya menduplikasi data minoritas secara acak (yang seringkali menyebabkan masalah overfitting), SMOTE bekerja dengan cara mensintesis atau membangkitkan data baru buatan. Algoritma ini memilih titik data minoritas secara acak, mencari tetangga terdekatnya (k-nearest neighbors), dan kemudian menghasilkan titik data baru di sepanjang garis yang menghubungkan titik-titik tersebut.

Penerapan Eksekusi SMOTE:
Hal yang sangat penting dalam pendekatan ini adalah bahwa SMOTE hanya diterapkan pada data latih (X_train dan y_train). Data uji (X_test dan y_test) sama sekali tidak boleh disentuh oleh algoritma resampling. Hal ini dilakukan untuk menghindari data leakage (kebocoran informasi) dan memastikan bahwa saat model dievaluasi, model tersebut sedang diuji menggunakan data dengan distribusi asli yang mencerminkan kondisi dunia nyata di mana kasus penipuan memang sangat jarang terjadi. Setelah penerapan SMOTE, jumlah sampel kelas Normal dan Fraud di data latih menjadi seimbang (masing-masing 227.451 sampel).

3. Pembangunan Model dan Metrik Evaluasi

Pada praktikum ini, algoritma yang digunakan untuk pemodelan adalah Random Forest Classifier, yang merupakan salah satu bentuk Ensemble Method berbasis bagging (Bootstrap Aggregating). Random Forest membangun banyak pohon keputusan (decision trees) dan mengambil mayoritas voting untuk menentukan prediksi akhir. Metode ini dipilih karena sangat kuat (robust), tahan terhadap outlier, dan secara inheren mampu menangani pola data non-linear dengan baik.

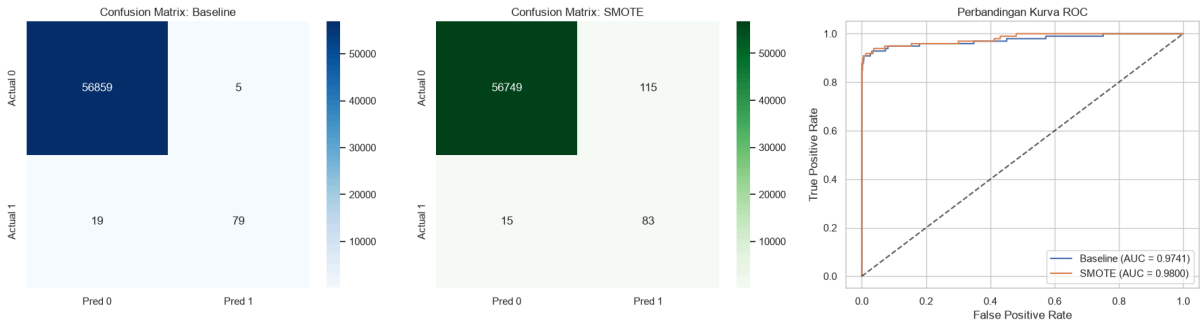
Untuk melihat dampak dari penanganan *class imbalance*, dua model dibangun dan dibandingkan:

- Model Baseline: Random Forest yang dilatih menggunakan data asli yang masih *imbalance*.

- Model SMOTE: Random Forest yang dilatih menggunakan data yang telah diseimbangkan dengan algoritma SMOTE.
-

Kedua model kemudian diprediksi ke data uji (X_test) dan dievaluasi menggunakan metrik Precision, Recall, F1-Score, dan ROC-AUC, dengan fokus penilaian pada performa model dalam mengenali kelas Fraud (Class 1).

Metrik Evaluasi (	Model Baseline	Model dengan SMOTE
Precision	9,405	4,192
Recall	8,061	8,469
F1-Score	8,681	5,608
ROC-AUC	9,741	9,800



4. Analisis Perbandingan dan Kesimpulan

Berdasarkan tabel metrik dan visualisasi Confusion Matrix serta kurva ROC di atas, dapat dilakukan analisis komparatif sebagai berikut:

1. Kelemahan Penggunaan Akurasi (Accuracy)
Seperti yang terlihat pada Classification Report (pada kode notebook), akurasi kedua model mencapai angka 1.00 (atau ~99%). Hal ini membuktikan hipotesis awal bahwa akurasi adalah metrik yang menyesatkan untuk dataset dengan ketidakseimbangan kelas ekstrem. Oleh karena itu, analisis harus dititikberatkan pada metrik Recall dan Precision.

2. Peningkatan Recall pada Model SMOTE
Pada deteksi penipuan (fraud detection), Recall merupakan metrik yang paling krusial. Recall mengukur seberapa banyak transaksi penipuan aktual yang berhasil dideteksi oleh model. Model Baseline hanya mampu mendeteksi sekitar 80,61% penipuan (terdapat False Negatives yang cukup besar). Setelah menggunakan SMOTE, Recall meningkat secara signifikan menjadi 84,69%. Ini berarti model menjadi jauh lebih sensitif dan lebih baik dalam menangkap kejahatan, meminimalisir kemungkinan ada transaksi penipuan yang lolos.

3. Trade-off pada Precision dan F1-Score
Peningkatan nilai Recall pada SMOTE harus mengorbankan metrik Precision. Precision pada model Baseline sangat tinggi (0.9405), namun turun tajam pada model SMOTE (0.4192). Hal ini tercermin jelas pada Confusion Matrix, di mana model SMOTE memprediksi lebih banyak transaksi legal sebagai transaksi Fraud (False Positives meningkat). Karena penurunan drastis pada Precision ini, F1-Score (rata-rata harmonik dari Precision dan Recall) pada model SMOTE juga ikut turun.

4. Peningkatan Nilai ROC-AUC
Metrik Area Under the Receiver Operating Characteristic Curve (ROC-AUC) mengevaluasi seberapa baik model dapat memisahkan antara kelas positif dan negatif secara keseluruhan pada berbagai threshold. Terlihat bahwa model dengan SMOTE memiliki skor ROC-AUC (0.9800) yang sedikit lebih baik dibandingkan Baseline (0.9741), menunjukkan bahwa kemampuan diskriminasi model secara garis besar mengalami perbaikan setelah disuplai dengan data sintetis.

Kesimpulan Akhir
Penggunaan Ensemble Method (Random Forest) dipadukan dengan teknik penanganan class imbalance (SMOTE) memberikan dampak yang sangat positif dalam konteks fraud detection. Dalam kasus nyata industri finansial dan perbankan, kerugian uang dan reputasi akibat gagal mendeteksi penipuan (False Negative) jauh lebih berakibat fatal dibandingkan ketidaknyamanan nasabah karena transaksinya tertunda akibat dicurigai sebagai penipuan (False Positive). Oleh karena itu, Model SMOTE dinilai jauh lebih superior dan sesuai untuk diimplementasikan karena berhasil memaksimalkan Recall, meskipun harus menoleransi trade-off penurunan pada Precision.