LAPORAN TUGAS PRAKTIKUM 2: PRAPROSES DATA

Nama: Maulana Rhys Pradana
NRP: 5054251041
Mata Kuliah: Praktikum Pengenalan Pemodelan Data / Machine Learning

1. Pengenalan dataset

   Pada praktikum ini, dataset yang digunakan adalah "House Prices - Advanced Regression Techniques" dari platform Kaggle. Dataset train.csv yang diimpor ke dalam pandas DataFrame memiliki dimensi awal sebanyak 1460 baris dan 81 kolom. Kolom-kolom tersebut terdiri dari fitur bertipe float64 (3 fitur), int64 (35 fitur), dan object atau kategorikal (43 fitur).

2. Langkah - Langkah

   2.1 Pembersihan data

   Dataset dunia nyata sering kali memiliki nilai yang hilang (missing values) yang dapat menyebabkan error pada algoritma Machine Learning. Pembersihan data diawali dengan menghitung persentase proporsi nilai yang hilang pada setiap atribut dataset. Berdasarkan ketentuan, atribut yang proporsi missing value-nya melebihi ambang batas 50% dianggap terlalu minim informasi dan langsung dihapus dari dataset. Untuk kolom yang masih memiliki nilai hilang di bawah 50%, dilakukan proses imputasi untuk menambal kekosongan data. Atribut numerik diisi menggunakan nilai median dari masing-masing kolom, sedangkan atribut kategorikal diisi menggunakan nilai modus (kategori yang paling sering muncul).

   Hasil :

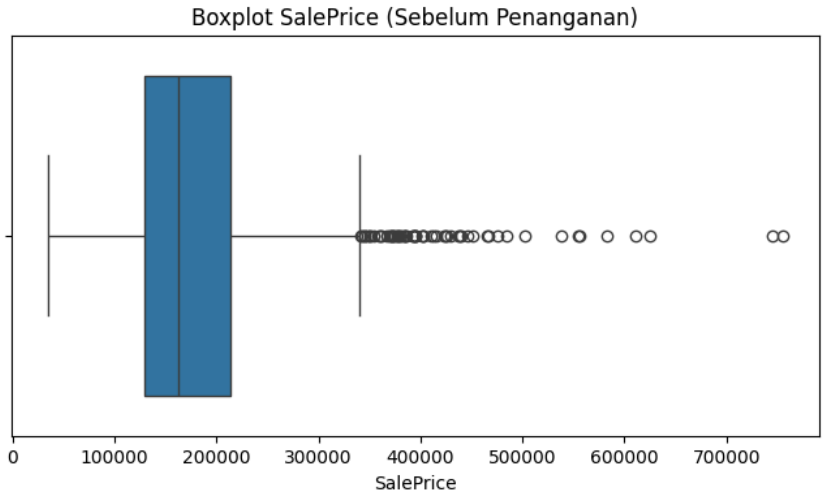
   - Berdasarkan proses identifikasi, terdapat 5 kolom atribut yang dihapus karena memiliki persentase kehilangan data di atas 50%, yaitu: Alley, MasVnrType, PoolQC, Fence, dan MiscFeature.
   - Sisa nilai yang hilang pada atribut lainnya berhasil ditangani menggunakan metode imputasi median dan modus, sehingga total sisa missing values pada dataset kini adalah 0.

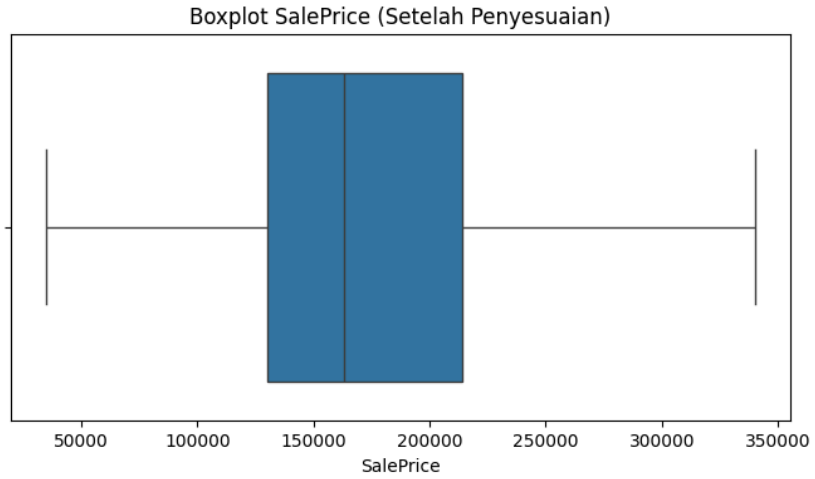
   2.2 Outlier

   Outlier atau pencilan adalah titik data yang nilainya menyimpang secara ekstrem dari mayoritas distribusi data. Deteksi outlier pada praktikum ini dilakukan secara visual menggunakan grafik Boxplot. Penanganan outlier dilakukan menggunakan metode penyesuaian nilai batas (capping) berbasis Interquartile Range (IQR) pada semua fitur numerik. Metode ini diimplementasikan dengan mencari rentang batas bawah (Q1 - 1.5 * IQR) dan batas atas (Q3 + 1.5 * IQR). Data yang nilainya melebihi batas

atas akan diubah paksa menjadi sama dengan batas atas, dan data yang kurang dari batas bawah akan diubah menjadi nilai batas bawah. Penyesuaian ini dipilih alih-alih penghapusan (dropping) baris agar model tidak kehilangan terlalu banyak informasi dari dataset yang hanya memiliki 1460 baris.

Hasil :





Dari visualisasi boxplot yang dihasilkan di atas, terlihat jelas bahwa sebelum penanganan, variabel seperti SalePrice memiliki banyak titik hitam (pencilan) di luar whisker batas atas grafik. Setelah dilakukan proses capping, titik-titik pencilan tersebut menghilang karena nilainya telah dirapatkan pada batas maksimum whisker, membuat distribusi varians data menjadi lebih padat dan stabil.

2.3. Transformasi Data

Banyak algoritma machine learning dan reduksi dimensi (seperti PCA) sangat sensitif terhadap skala fitur. Oleh karena itu, seluruh fitur numerik (kecuali kolom Id dan fitur target SalePrice) distandarisasi menggunakan algoritma StandardScaler sehingga setiap fitur memiliki rata-rata (mean) 0 dan standar deviasi 1.

Selanjutnya, karena model regresi tidak dapat membaca tipe data teks, seluruh atribut kategoris dikonversi menjadi format biner (numeric) menggunakan metode One-Hot Encoding melalui library pandas.get_dummies. Parameter drop_first=True juga digunakan dalam encoding ini untuk menghindari masalah multikolinearitas (dummy variable trap).

Hasil :

Akibat ekspansi pemecahan nilai kategori pada tahapan One-Hot Encoding, jumlah atribut mengalami peningkatan yang sangat pesat. Dimensi dataset yang awalnya memiliki kurang dari 80 kolom kini melebar drastis menjadi (1460 baris, 235 kolom).

2.4. Reduksi Dimensi

Dengan membengkaknya fitur menjadi 235 kolom, dataset rentan mengalami curse of dimensionality (kutukan dimensi) yang bisa menyebabkan overfitting. Reduksi dimensi dilakukan dalam dua tahap:

- Analisis Korelasi: Menghitung korelasi Pearson absolut antar fitur numerik. Jika ditemukan pasangan fitur dengan korelasi saling tumpang tindih (> 0.8), salah satu fitur dari pasangan tersebut akan dibuang.
- Principal Component Analysis (PCA): Mengompres fitur-fitur independen menggunakan metode statistik PCA. PCA dikonfigurasi untuk mengekstrak komponen utama yang mampu menguraikan (mempertahankan) minimal 95% varians (informasi) penting dari data aslinya.

Hasil :

- Tahap analisis korelasi Pearson menemukan beberapa fitur yang sangat berkorelasi kuat (redundan). Oleh karena itu, terdapat 3 atribut yang dieliminasi atau dihapus, yaitu: 1stFlrSF, TotRmsAbvGrd, dan GarageArea.
- Setelah fitur dipangkas, algoritma PCA dijalankan dan secara signifikan berhasil meringkas ratusan dimensi matriks. Model PCA meringkas keseluruhan informasi prediktor menjadi hanya 65 komponen utama (Principal Components) saja namun tetap menahan 95% variasi data orisinal.

3. Ringkasan Dataset Akhir
    - Fitur Final: DataFrame hasil akhir disusun ulang dan memuat 65 kolom komponen utama PCA (dinamai PC1 hingga PC65) sebagai kumpulan variabel independen.
    - Kolom Utuh: Kolom target SalePrice (sebagai label) dan identifier Id dilekatkan kembali secara utuh ke dalam dataset tanpa perubahan skala maupun reduksi agar mudah divalidasi dan dinilai hasilnya.

- Dimensi Final: Secara keseluruhan, reduksi sukses menyusutkan struktur data yang sempat melebar 235 dimensi, turun menjadi 67 dimensi kolom padat informasi (65 kolom PC + 1 SalePrice + 1 Id) dan tetap memiliki 1460 baris pengamatan